

# Análisis Espacial del Costo Total de la Actividad Agropecuaria en la Región Puno

Ilma Magda Mamani Mamani  
Facultad de Estadística e Informática  
Universidad Nacional del Altiplano - Puno

15 de octubre de 2025

## Resumen

Este documento presenta un análisis espacial completo del costo total de la actividad agropecuaria en la región Puno durante el año 2024. Se implementaron técnicas de econometría espacial incluyendo matrices de pesos espaciales, índices de autocorrelación (Moran I y Geary C) y análisis de hotspots mediante Local Moran I (LISA) y Getis-Ord  $G_i^*$ . Los resultados revelan patrones significativos de concentración espacial en los gastos agropecuarios.

## 1. Introducción

El análisis espacial permite identificar patrones de concentración geográfica en fenómenos económicos. En este estudio, se analiza la distribución espacial de los costos de actividades agropecuarias en 90 distritos de la región Puno, utilizando el software R con las librerías `sf`, `spdep`, `geodata` y `terra`.

## 2. Metodología

### 2.1. Datos

- **Fuente:** Datos del Capítulo 1000 - Actividad Agropecuaria
- **Unidades:** 90 distritos de Puno
- **Variable principal:** Costo total (gastos agrícolas + gastos pecuarios)
- **Estadísticas descriptivas:**
  - Mínimo: S/ 1,460
  - Mediana: S/ 87,979
  - Media: S/ 157,756
  - Máximo: S/ 922,562

## 2.2. Matrices de Pesos Espaciales

Se construyeron dos matrices de pesos espaciales:

### 1. Matriz K-Vecinos más Cercanos (KNN):

- $K = 5$  vecinos más cercanos
- Promedio de vecinos: 5.0
- Normalización: Row-standardized (W)

### 2. Matriz por Distancia:

- Umbral de distancia: 1 km
- Promedio de vecinos: 43.44
- Todos los distritos dentro del umbral son considerados vecinos

## 3. Resultados

### 3.1. Distribución Espacial de Costos

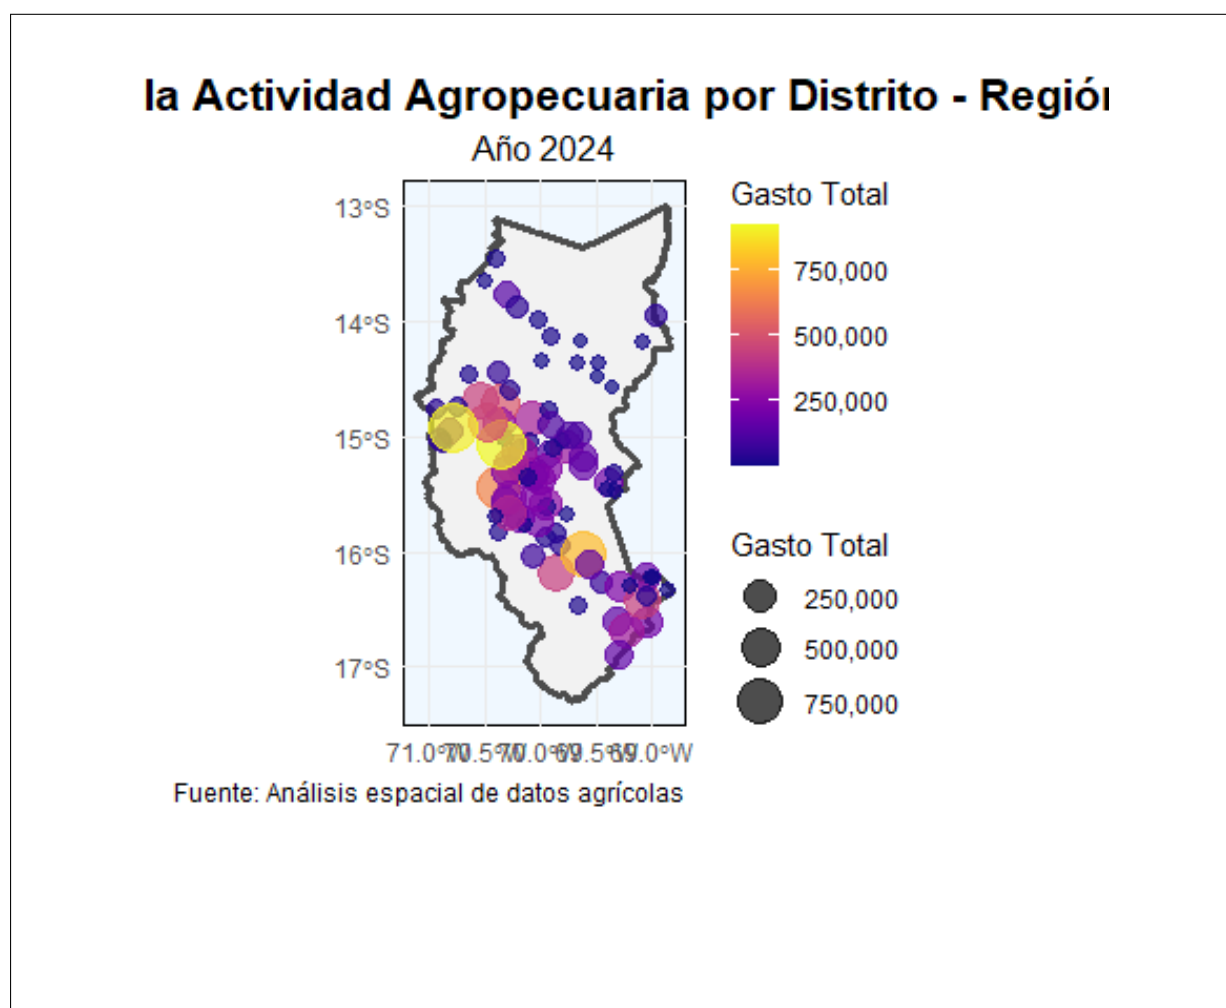


Figura 1: Distribución espacial del costo total de la actividad agropecuaria por distrito en Puno

El mapa muestra una distribución heterogénea de los costos agropecuarios en Puno, con mayores concentraciones en las provincias de Azángaro, Lampa y Melgar.

### 3.2. Índice I de Moran

El índice I de Moran mide la autocorrelación espacial global:

Estadístico	Valor
I de Moran	0.1399
Valor esperado	-0.0112
Z-score	2.5574
P-valor	0.0053

Cuadro 1: Resultados del índice I de Moran

#### Interpretación:

- El valor  $I = 0.1399$  es **positivo y significativo** ( $p < 0.05$ )
- Existe **autocorrelación espacial positiva**: los distritos con gastos similares tienden a agruparse geográficamente
- La prueba de Monte Carlo (999 permutaciones) confirma la significancia ( $p = 0.02$ )

### 3.3. Índice C de Geary

El índice C de Geary complementa el análisis de autocorrelación:

Estadístico	Valor
C de Geary	0.8256
Z-score	2.2744
P-valor	0.0115

Cuadro 2: Resultados del índice C de Geary

#### Interpretación:

- $C = 0.8256 < 1$ , lo que indica **autocorrelación positiva**
- El resultado es significativo ( $p < 0.05$ )
- Confirma que valores similares tienden a estar próximos espacialmente
- Geary C es más sensible a diferencias locales que Moran I

### 3.4. Diagrama de Dispersión de Moran




Figura 2: Enter Caption

Figura 3: Diagrama de dispersión de Moran mostrando la relación entre valores estandarizados y su lag espacial

El diagrama muestra la relación entre cada observación y sus vecinos, confirmando la tendencia de agrupamiento espacial.

### 3.5. Análisis de Hotspots (LISA)

El análisis Local Moran I (LISA) identifica clusters locales:

Categoría	Frecuencia
High-High (Hotspot)	2
Low-High (Outlier)	3
No Significativo	85

Cuadro 3: Clasificación LISA de distritos

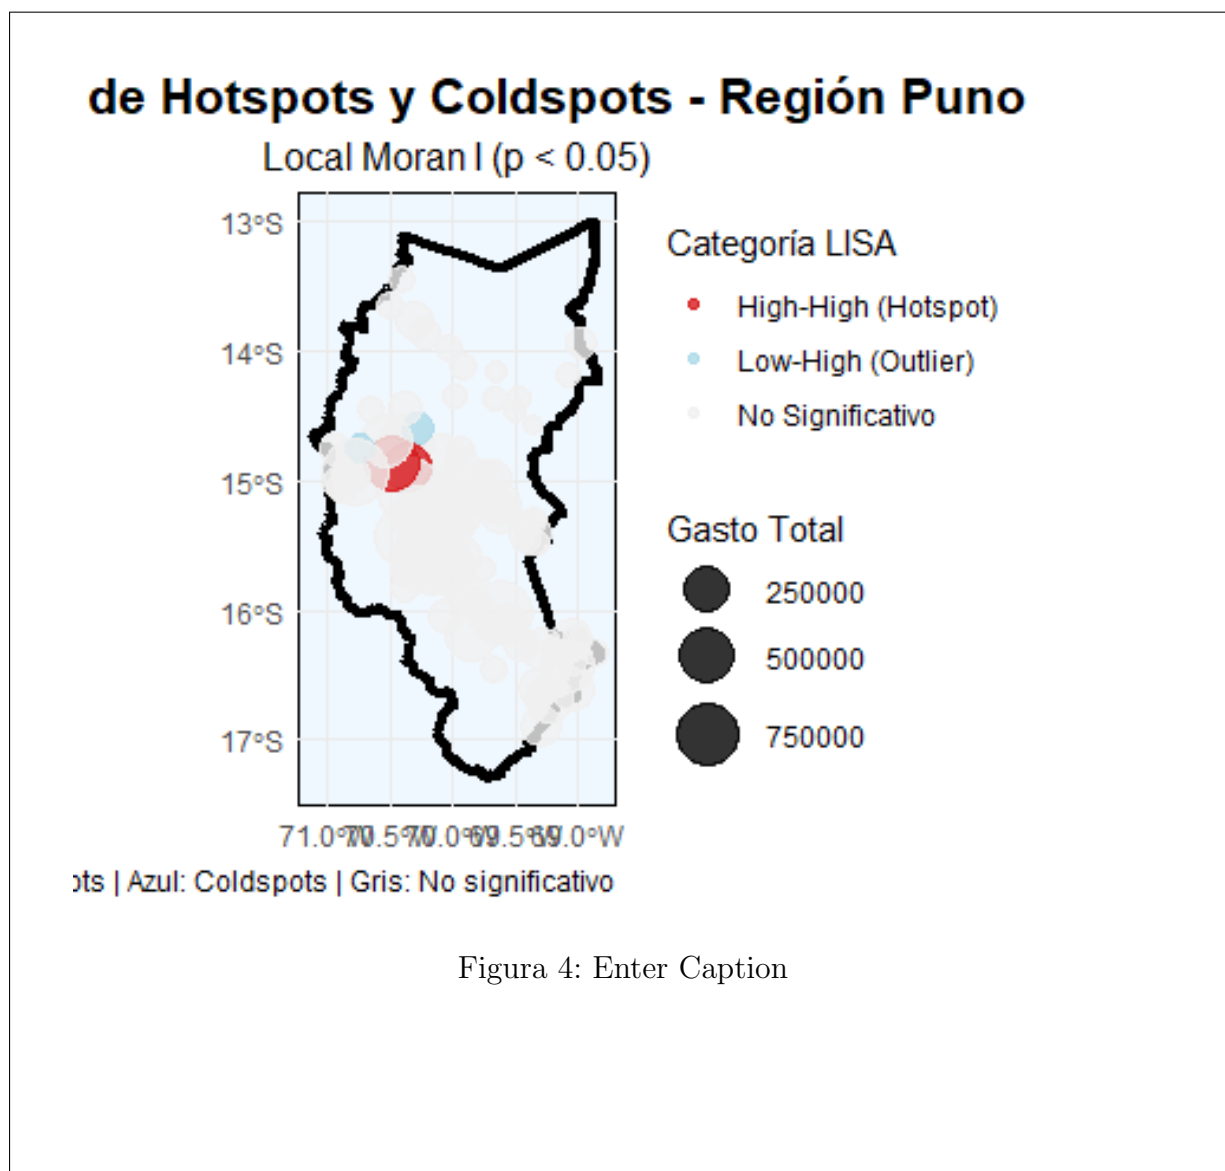


Figura 5: Mapa de hotspots y coldspots según análisis LISA

#### Interpretación:

- **Hotspots (High-High):** 2 distritos con altos gastos rodeados de distritos con altos gastos
- **Outliers (Low-High):** 3 distritos con bajos gastos rodeados de distritos con altos gastos
- El 94 % de los distritos no muestra autocorrelación local significativa

3.6. Análisis Getis-Ord Gi\*

El estadístico Gi\* identifica concentraciones espaciales estadísticamente significativas:

Categoría	Frecuencia
Hotspot (99 %)	4
Hotspot (95 %)	1
Hotspot (90 %)	3
Coldspot (90 %)	9
No Significativo	73

Cuadro 4: Clasificación Getis-Ord Gi\*




Figura 6: Enter Caption

Figura 7: Mapa de análisis Getis-Ord Gi\* mostrando hotspots y coldspots

Interpretación:

- **Hotspots:** 8 distritos con alta concentración de gastos (99 %, 95 %, 90 % de confianza)
- **Coldspots:** 9 distritos con baja concentración de gastos (90 % de confianza)
- Gi\* detecta más clusters que LISA debido a su mayor sensibilidad

### 3.7. Análisis por Provincias

Provincia	Gasto Total	N° Distritos	Gasto Promedio
Azángaro	2,408,174	13	185,244
Lampa	2,393,312	6	398,885
Melgar	2,207,066	9	245,230
Chucuito	1,569,674	7	224,239
Puno	1,519,823	13	116,910

Cuadro 5: Top 5 provincias por gasto total agropecuario

Las provincias de Azángaro, Lampa y Melgar concentran el 44 % del gasto total regional, indicando una fuerte concentración espacial de la actividad agropecuaria.

## 4. Código R Implementado

```
# 1. MATRICES DE PESOS
library(spdep)
coords <- st_coordinates(datos_sf)

# Matriz KNN
vecinos_knn <- knn2nb(knearneigh(coords, k=5))
pesos_knn <- nb2listw(vecinos_knn, style="W")

# Matriz por distancia
vecinos_dist <- dnearneigh(coords, 0, umbral)
pesos_dist <- nb2listw(vecinos_dist, style="W")

# 2. NDICE I DE MORAN
moran_knn <- moran.test(datos_sf$GASTO_TOTAL,
                        pesos_knn)

# 3. NDICE C DE GEARY
geary_knn <- geary.test(datos_sf$GASTO_TOTAL,
                        pesos_knn)

# 4. ANALISIS DE HOTSPOTS
# LISA (Local Moran I)
local_moran <- localmoran(datos_sf$GASTO_TOTAL,
                           pesos_knn)

# Getis-Ord Gi*
```

```
local_g <- localG(datos_sf$GASTO_TOTAL,
                  pesos_knn)
```

## 5. Conclusiones

1. Se confirmó la existencia de **autocorrelación espacial positiva significativa** en los costos agropecuarios de Puno (Moran I = 0.1399,  $p < 0.01$ ).
2. El índice C de Geary (0.8256) corrobora el patrón de agrupamiento, siendo más sensible a variaciones locales.
3. Se identificaron **8 hotspots** (concentraciones de altos gastos) y **9 coldspots** (concentraciones de bajos gastos) mediante el análisis Getis-Ord  $G_i^*$ .
4. Las provincias de **Azángaro, Lampa y Melgar** concentran la mayor actividad agropecuaria, representando el 44 % del gasto total regional.
5. La matriz KNN ( $k=5$ ) fue más efectiva que la matriz de distancia para capturar relaciones espaciales relevantes en este contexto.
6. Los resultados sugieren políticas diferenciadas: fortalecimiento en hotspots y promoción en coldspots.

## 6. Referencias

- Anselin, L. (1995). Local Indicators of Spatial Association—LISA. *Geographical Analysis*, 27(2), 93-115.
- Getis, A., & Ord, J. K. (1992). The Analysis of Spatial Association by Use of Distance Statistics. *Geographical Analysis*, 24(3), 189-206.
- Bivand, R., & Wong, D. W. (2018). Comparing implementations of global and local indicators of spatial association. *TEST*, 27(3), 716-748.